



预测泰坦尼克号旅客生存概率



数据准备

数据准备

下载泰坦尼克号旅客的数据集

```
import urllib.request
import os

data_url="http://biostat.mc.vanderbilt.edu/wiki/pub/Main/DataSets/titanic3.xls"
data_file_path="data/titanic3.xls"

if not os.path.isfile(data_file_path):
    result=urllib.request.urlretrieve(data_url,data_file_path)
    print('downloaded:',result)
else:
    print(data_file_path,'data file already exists.')
```

读取数据

```
import numpy
import pandas as pd

# 读取数据文件，结果为DataFrame格式
df_data = pd.read_excel(data_file_path)
```

筛选提取需要的特征字段

```
#筛选提取需要的特征字段，去掉ticket, cabin等
selected_cols=['survived','name','pclass','sex','age','sibsp','parch','fare','embarked']
selected_df_data=df_data[selected_cols]
```

定义数据预处理函数

```
from sklearn import preprocessing

def prepare_data(df_data):
    df=df_data.drop(['name'], axis=1) #删除姓名列
    age_mean = df['age'].mean()
    df['age'] = df['age'].fillna(age_mean) #为缺失age记录填充值
    fare_mean = df['fare'].mean()
    df['fare'] = df['fare'].fillna(fare_mean) #为缺失fare记录填充值
    df['sex']= df['sex'].map({'female':0, 'male': 1}).astype(int) #把sex值由字符串转换为数值
    df['embarked'] = df['embarked'].fillna('S') #为缺失embarked记录填充值
    df['embarked']=df['embarked'].map({'C':0, 'Q': 1,'S': 2}).astype(int) #把embarked值由字符串转换为数值

    ndarray_data = df.values #转换为ndarray数组

    features = ndarray_data[:,1:] #后7列是特征值
    label = ndarray_data[:,0] #第0列是标签值

    # 特征值标准化
    minmax_scale = preprocessing.MinMaxScaler(feature_range=(0, 1))
    norm_features=minmax_scale.fit_transform(features)

    return norm_features,label
```



数据准备



浙江大學城市學院
ZHEJIANG UNIVERSITY CITY COLLEGE

shuffle, 打乱数据顺序, 为后面训练做准备

```
# shuffle, 打乱数据顺序, 通过Pandas的抽样函数sample实现, frac为百分比  
# selected_df_data数据保持不变
```

```
shuffled_df_data=selected_df_data.sample(frac=1)
```



得到处理后的数据集

```
x_data, y_data=prepare_data(shuffled_df_data)
```



划分训练集和测试集

```
train_size = int(len(x_data) *0.8)
```

```
x_train = x_data[:train_size]
```

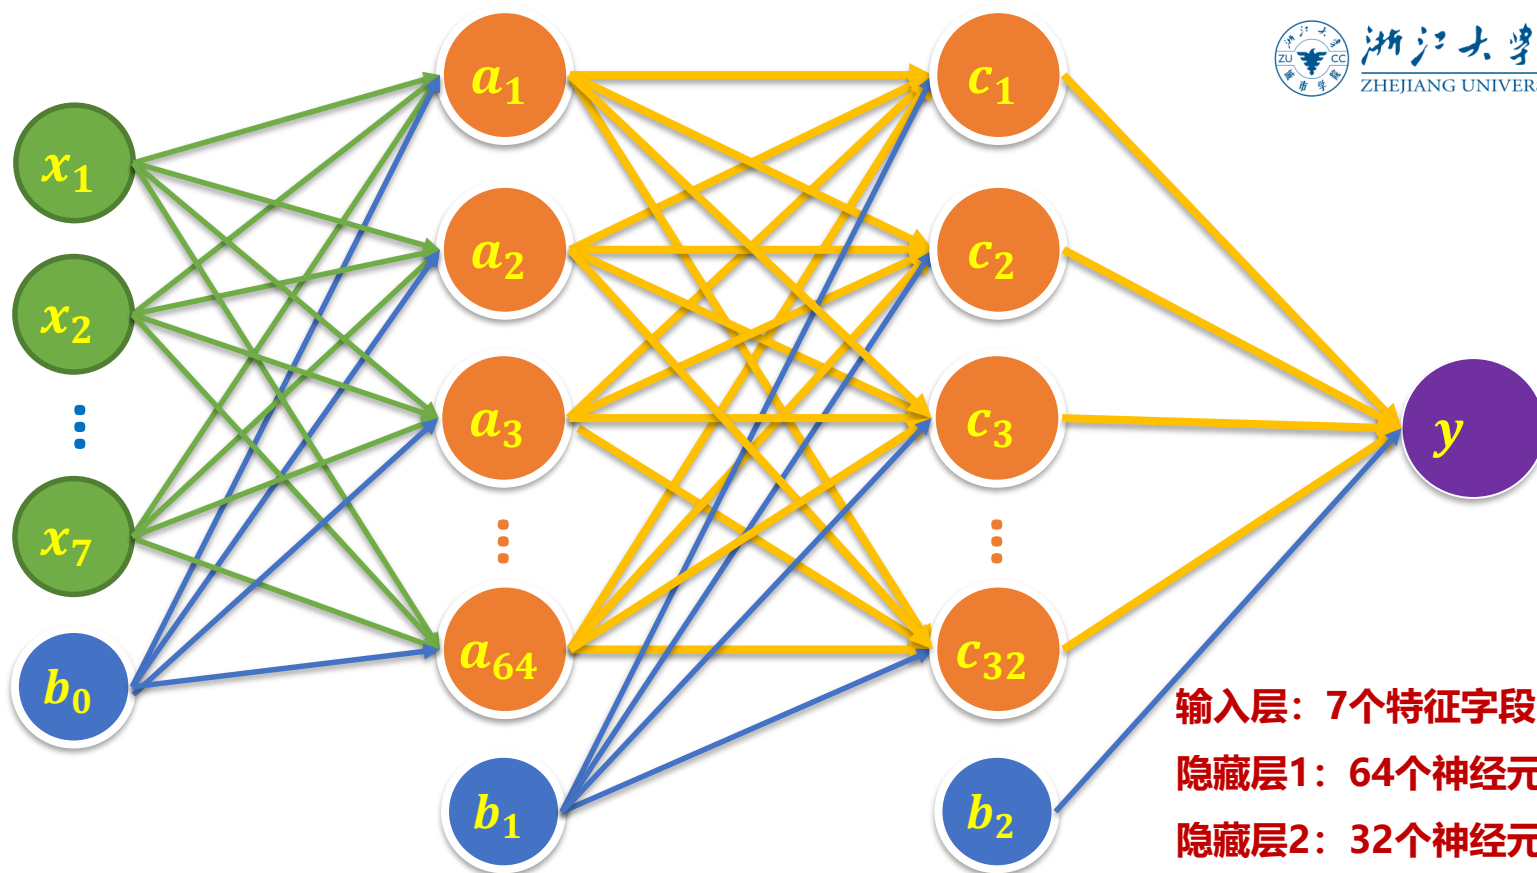
```
y_train = y_data[:train_size]
```

```
x_test = x_data[train_size:]
```

```
y_test = y_data[train_size:]
```



建立多层神经网络模型



输入层：7个特征字段 -> 7个神经元

隐藏层1：64个神经元

隐藏层2：32个神经元

输出层：1个神经元

输入层

隐藏层1

隐藏层2

输出层

建立模型结构

1

```
import tensorflow as tf

# 建立Keras序列模型
model = tf.keras.models.Sequential()
```

2


```
# 加入第一层，输入特征数据是7列，也可以用input_shape=(7,)
model.add(tf.keras.layers.Dense(units=64,
                                  input_dim=7,
                                  use_bias=True,
                                  kernel_initializer='uniform',
                                  bias_initializer='zeros',
                                  activation='relu'))
```

3

```
model.add(tf.keras.layers.Dense(units=32,
                                  activation='sigmoid'))
```

4

```
model.add(tf.keras.layers.Dense(units=1,
                                  activation='sigmoid'))
```






模型设置



模型结构



```
model.summary()
```

Layer (type)	Output Shape	Param #
dense (Dense)	(None, 64)	512
dense_1 (Dense)	(None, 32)	2080
dense_2 (Dense)	(None, 1)	33

Total params: 2,625

Trainable params: 2,625


Non-trainable params: 0



模型设置



```
model.compile(optimizer=tf.keras.optimizers.Adam(0.003),  
              loss='binary_crossentropy',  
              metrics=['accuracy'])
```



- **optimizer** 可以是优化器的名字，如 'adam'，也可以是优化器的实例
- **loss** 是损失函数名
 - 用 **sigmoid** 作为激活函数，一般损失函数选用 **binary_crossentropy**
 - 用 **softmax** 作为激活函数，一般损失函数选用 **categorical_crossentropy**
- **metrics** 模型要训练和评估的度量值

更多详细信息查阅API文档

https://www.tensorflow.org/versions/r1.10/api_docs/python/tf/keras/Model




浙江大学城市学院
ZHEJIANG UNIVERSITY CITY COLLEGE

模型训练

模型训练

```
train_history=model.fit(x=x_train,  
                        y=y_train,  
                        validation_split=0.2,  
                        epochs=100,  
                        batch_size=40,  
                        verbose=2)
```



Train on 837 samples, validate on 210 samples

Epoch 1/100

- 0s - loss: 0.3358 - acc: 0.8590 - val_loss: 0.5392 - val_acc: 0.7762

Epoch 2/100

- 0s - loss: 0.3346 - acc: 0.8578 - val_loss: 0.5384 - val_acc: 0.7857

- **x**:输入的特征数据 **y**:标签数据
- **validation_split**:验证集所占的比例
- **verbose**: 训练过程显示模式

取值 0: 不显示, 1: 带进度条模式, 2: 每epoch显示一行

- **返回值**: 过程历史对象, 包括训练过程的**loss**和**acc**数据, 以及验证过程的 (如果有)




模型训练



```
train_history.history
```

```
{'val_loss': [0.580418274516151,  
0.5365407637187413,  
0.49857869886216666,  
0.4796800400529589,  
0.4473303187461126,  
0.4379332661628723,  
0.4317010701000000]
```

```
, 'loss': [0.6573422585336965,  
0.5653840109723728,  
0.5279814491989792,  
0.4977049786984707,  
0.48072773634746513,  
0.46581221944257495,  
0.4604507074774807,
```



训练过程的历史数据：字典模式存储

```
train_history.history.keys()
```

```
dict_keys(['val_loss', 'val_acc', 'loss', 'acc'])
```



模型训练过程可视化



```
import matplotlib.pyplot as plt

def visu_train_history(train_history, train_metric, validation_metric):
    plt.plot(train_history.history[train_metric])
    plt.plot(train_history.history[validation_metric])
    plt.title('Train History')
    plt.ylabel(train_metric)
    plt.xlabel('epoch')
    plt.legend(['train', 'validation'], loc='upper left')
    plt.show()
```

```
visu_train_history(train_history, 'acc', 'val_acc')
```


```
visu_train_history(train_history, 'loss', 'val_loss')
```




模型训练过程可视化



```
visu_train_history(train_history, 'acc', 'val_acc')
```



```
visu_train_history(train_history, 'loss', 'val_loss')
```





模型评估



模型评估



```
evaluate_result = model.evaluate(x=x_test,  
                                 y=y_test)
```


```
262/262 [=====] - 0s 15us/step
```

```
evaluate_result
```

```
[0.49095327822306684, 0.7748091598503463]
```

```
model.metrics_names
```

```
['loss', 'acc']
```



- **model.metrics_names**: 评估结果返回值的标签



浙江大学城市学院
ZHEJIANG UNIVERSITY CITY COLLEGE

模型应用



应用模型进行预测



加入Jack & Rose的数据

Jack: 3等舱, 男性, 票价5, 年龄 23; Rose: 头等舱, 女性, 票价100, 年龄20

Jack和Rose的旅客信息

```
Jack_info = [0, 'Jack', 3, 'male', 23, 1, 0, 5.0000, 'S']
```

```
Rose_info = [1, 'Rose', 1, 'female', 20, 1, 0, 100.0000, 'S']
```

创建新的旅客DataFrame

```
new_passenger_pd=pd.DataFrame([Jack_info, Rose_info], columns=selected_cols)
```

在老的DataFrame中加入新的旅客信息

```
all_passenger_pd=selected_df_data.append(new_passenger_pd)
```



应用模型进行预测



加入Jack & Rose的数据

Jack: 3等舱, 男性, 票价5, 年龄 23; Rose: 头等舱, 女性, 票价100, 年龄20

```
all_passenger_pd[-3:]
```

	survived	name	pclass	sex	age	sibsp	parch	fare	embarked
1308	0	Zimmerman, Mr. Leo	3	male	29.0	0	0	7.875	S
0	0	Jack	3	male	23.0	1	0	5.000	S
1	1	Rose	1	female	20.0	1	0	100.000	S



执行预测



再次执行数据预处理，然后使用model.predict执行预测

```
# 数据准备
```

```
x_features, y_label = prepare_data(all_passenger_pd)
```

```
# 利用模型计算旅客生存概率
```

```
surv_probability = model.predict(x_features)
```

```
surv_probability[:5]
```

```
array([[0.98063767],  
       [0.7744939 ],  
       [0.988727  ],  
       [0.43560937],  
       [0.9756891 ]], dtype=float32)
```



查看预测结果



合并数据，查看预测结果

```
# 在数据表最后一列插入生存概率
```

```
all_passenger_pd.insert(len(all_passenger_pd.columns), 'surv_probability', surv_probability)
```

```
all_passenger_pd[-5:]
```

	survived	name	pclass	sex	age	sibsp	parch	fare	embarked	surv_probability
1306	0	Zakarian, Mr. Mapriededer	3	male	26.5	0	0	7.225	C	0.200157
1307	0	Zakarian, Mr. Ortin	3	male	27.0	0	0	7.225	C	0.196501
1308	0	Zimmerman, Mr. Leo	3	male	29.0	0	0	7.875	S	0.150551
0	0	Jack	3	male	23.0	1	0	5.000	S	0.147279
1	1	Rose	1	female	20.0	1	0	100.000	S	0.992087



模型训练日志记录、模型存储的实现

—

模型训练过程中的回调



模型回调参数设置



```
# 设置回调参数，内置的回调还包括：  
# tf.keras.callbacks.LearningRateScheduler()  
# tf.keras.callbacks.EarlyStopping  
  
logdir = './logs'  
checkpoint_path = './checkpoint/Titanic.{epoch:02d}-{val_loss:.2f}.ckpt'  
  
callbacks = [  
    tf.keras.callbacks.TensorBoard(log_dir=logdir,  
                                    histogram_freq=2),  
    tf.keras.callbacks.ModelCheckpoint(filepath=checkpoint_path,  
                                        save_weights_only=True,  
                                        verbose=1,  
                                        period=5)  
]
```




模型训练



```
train_history=model.fit(x=x_train,  
                        y=y_train,  
                        validation_split=0.2,  
                        epochs=100,  
                        batch_size=40,  
                        callbacks=callbacks,  
                        verbose=2)
```



查看模型训练日志文件



浙江大學城市學院
ZHEJIANG UNIVERSITY CITY COLLEGE

TensorFlowCodes > TF_ZUCC_16_KERAS > logs

名称	修改日期	类型	大小
 events.out.tfevents.1546704071.MINGHUIWU	2019/1/6 0:01	MINGHUIWU 文件	2,936 KB



查看模型存储文件



TensorFlowCodes > TF_ZUCC_16_KERAS > checkpoint

名称	修改日期	类型	大小
checkpoint	2019/1/6 0:01	文件	1 KB
Titanic.80-0.41.ckpt.data-00000-of-00001	2019/1/6 0:01	DATA-00000-OF-0...	15 KB
Titanic.80-0.41.ckpt.index	2019/1/6 0:01	INDEX 文件	1 KB
Titanic.85-0.42.ckpt.data-00000-of-00001	2019/1/6 0:01	DATA-00000-OF-0...	15 KB
Titanic.85-0.42.ckpt.index	2019/1/6 0:01	INDEX 文件	1 KB
Titanic.90-0.44.ckpt.data-00000-of-00001	2019/1/6 0:01	DATA-00000-OF-0...	15 KB
Titanic.90-0.44.ckpt.index	2019/1/6 0:01	INDEX 文件	1 KB
Titanic.95-0.41.ckpt.data-00000-of-00001	2019/1/6 0:01	DATA-00000-OF-0...	15 KB
Titanic.95-0.41.ckpt.index	2019/1/6 0:01	INDEX 文件	1 KB
Titanic.100-0.42.ckpt.data-00000-of-00001	2019/1/6 0:01	DATA-00000-OF-0...	15 KB
Titanic.100-0.42.ckpt.index	2019/1/6 0:01	INDEX 文件	1 KB